

SIMULADOR INTELIGENTE DE OCUPACIÓN HOSPITALARIA

Fase 3 — Preparación del Dato

Proyecto	Prototipo académico funcional · Curso IA en Salud
Fase	F3 — SEMMA·Explore+Modify · Preparación del dato
Autor	Juan Camilo García Braham
Programa	Maestría en IA y Ciencia de Datos
Institución	Universidad Tecnológica de Pereira (UTP)
Marco	CRISP-DM/S · SEMMA · DAMA · MLOps
Año	2026

Resumen ejecutivo

Este documento constituye el entregable completo de la Fase 3 (Preparación del Dato) del Simulador Inteligente de Ocupación Hospitalaria, desarrollado bajo el framework CRISP-DM/S con subciclo SEMMA·Explore+Modify. Contiene: (1) el módulo generador de pacientes sintéticos con distribuciones calibradas provenientes de F2; (2) el análisis exploratorio del dato sintético (EDA) sobre un lote de 500 pacientes con validación estadística de proporciones, rangos y distribuciones; y (3) el registro formal de parámetros definitivos post-EDA con trazabilidad completa. El criterio de salida de F3 se declara cumplido.

TABLA DE CONTENIDO

Entregable 1: Módulo Generador de Pacientes Sintéticos	3
· 1. Decisiones de stack y diseño aprobadas	3
· 2. Funciones del módulo	3
· 3. Estructura de salida — PacienteDict (D_F3_002)	4
· 4. Parámetros de distribuciones implementados	4
Entregable 2: Análisis Exploratorio del Dato Sintético (EDA)	5
· 1. Configuración del lote EDA	5
· 2. Análisis 1 — Proporciones de prioridad clínica (R09)	5
· 3. Análisis 2 — Tiempos de estancia por área	6
· 4. Análisis 3 — Correspondencia prioridad × área (D011)	7
· 5. Análisis 4 — Validación de rangos (D005)	8
· 6. Análisis 5 — Llegadas Poisson por escenario (D012)	9
Entregable 3: Parámetros Definitivos Post-EDA	10
· 1. Registro consolidado de parámetros calibrados	10
· 2. Criterio de salida de F3 — Verificación	11
· 3. Registro consolidado de decisiones de F3	11
· 4. Estado de riesgos activos al cierre de F3	12

ENTREGABLE 1

Módulo Generador de Pacientes Sintéticos

El módulo `generador_pacientes.py` implementa la generación de pacientes sintéticos utilizando las distribuciones probabilísticas especificadas en F2. Está diseñado para ser importado como módulo por el EDA (F3) y por el sistema experto (F4-A), sin dependencia de pandas ni de ninguna librería de visualización.

1. Decisiones de stack y diseño aprobadas

ID	Decisión	Detalle
Stack F3	Opción B aprobada	numpy · scipy · pandas · matplotlib · seaborn
D_F3_001	Semilla aleatoria global	SEED = 42; pasada explícitamente a <code>numpy.random.default_rng()</code>
D_F3_002	Estructura de salida	Lista de dicts (<code>PacienteDict</code>); máxima portabilidad sin acoplamiento temprano a pandas

Tabla D-F3. Decisiones de diseño aprobadas para F3

2. Funciones del módulo

Función	Propósito	Parámetros clave
<code>generar_pacientes_lote()</code>	Núcleo: genera n pacientes con todas las distribuciones de F2	<code>n_pacientes</code> , <code>tick_ingreso</code> , <code>escenario</code> , <code>rng</code>
<code>generar_llegadas_tick()</code>	Simula un tick: muestrea $Poisson(\lambda)$ y llama al núcleo	<code>tick</code> , <code>escenario</code> , <code>rng</code>
<code>generar_lote_eda()</code>	Conveniencia para EDA: lote de tamaño fijo con semilla explícita	<code>n=500</code> , <code>escenario</code> , <code>seed=42</code>

Tabla 1. Funciones públicas del módulo `generador_pacientes.py`

3. Estructura de salida — PacienteDict (D_F3_002)

Cada paciente generado es un diccionario tipado (**TypedDict**) con los atributos de la entidad Paciente definidos en F2. Los campos calculados se inicializan con valores neutros; serán actualizados por el sistema experto en F4-A.

Campo	Tipo	Valor al ingreso	Fuente
<code>id_paciente</code>	str	UUID v4 generado	Generado
<code>edad</code>	int	[0, 110] años	Normal truncada
<code>prioridad_clinica</code>	str	P1 P2 P3 P4	Multinomial
<code>area_requerida</code>	str	Condicional a prioridad	Categórica D011
<code>tiempo_estancia_esperado</code>	float	[0.25, 720.0] h	Log-normal truncada D005
<code>tiempo_espera</code>	float	0.0 (neutro)	Calculado F4-A
<code>tiempo_en_sistema</code>	float	0.0 (neutro)	Calculado F4-A
<code>estado</code>	str	esperando	F2 Tabla 5
<code>cama_id</code>	None	null al ingreso	F2 Tabla 5 invariante
<code>tick_ingreso</code>	int	tick actual	Parámetro de entrada
<code>es_desborde</code>	bool	False	D007 — False al ingreso

Tabla 2. Estructura PacienteDict — atributos de salida del generador

4. Parámetros de distribuciones implementados

Variable	Distribución	Parámetros	Implementación
Llegada / tick	Poisson(λ) — D012	Normal: 1.5 · Alta: 3.0 · Crisis: 5.0	rng.poisson(lambda)
Prioridad clínica	Multinomial	p = [0.05, 0.20, 0.45, 0.30]	rng.choice(indices, p=probs)
Area requerida	Categórica cond. — D011	Por prioridad (F2 Tabla 11)	rng.choice(areas, p=probs)
Tiempo estancia	Log-normal trunc. — D005	mu/sigma por area; [0.25, 720] h	exp(mu + sigma*rng.standard_normal()) + rechazo
Edad	Normal truncada	mu=45 sigma=20 [0, 110] años	scipy.stats.truncnorm.rvs(..., random_state=rng)

Tabla 3. Distribuciones implementadas en el generador — parámetros finales de F2

✓ **Decisión registrada** — D_F3_001 — SEED = 42 como semilla global del generador. Se instancia una única vez con `numpy.random.default_rng(42)` y se pasa en cadena a todas las funciones de muestreo. Garantiza reproducibilidad total independientemente del estado global de Python o numpy.

✓ **Decisión registrada** — D_F3_002 — Salida del generador como lista de dicts (PacienteDict). Máxima portabilidad: conversión trivial a DataFrame para el EDA (`pd.DataFrame(lote)`) y a dataclasses con estado en F4-A, sin acoplar el generador a ninguna librería de visualización o ORM.

ENTREGABLE 2

Análisis Exploratorio del Dato Sintético (EDA)

El EDA se ejecuta sobre un lote de 500 pacientes generados con `generar_lote_eda(n=500, seed=42)`. El objetivo es verificar que las distribuciones implementadas reproducen fielmente las especificaciones de F2 y que no existen valores fuera de rango. El script `eda_pacientes.py` produce 5 figuras PNG independientes, reproducibles con la misma semilla en cualquier entorno con el stack aprobado.

1. Configuración del lote EDA

Parámetro	Valor	Justificación
n_pacientes	500	Mínimo del criterio de salida de F3; suficiente para estabilizar proporciones
seed	42 (D_F3_001)	Reproducibilidad total; resultados idénticos en cualquier ejecución local
escenario	normal	Escenario base; las distribuciones de paciente son independientes del escenario
n_fijo	No Poisson	El lote EDA usa n fijo (no Poisson) para controlar el tamaño de muestra exacto

Tabla 4. Configuración del lote para el EDA

2. Análisis 1 — Proporciones de prioridad clínica (R09)

Se comparan las proporciones observadas en el lote con el vector teórico de F2 mediante un **test chi-cuadrado (chi-2) de bondad de ajuste**. La hipótesis nula es que la distribución observada proviene de la Multinomial($p=[0.05, 0.20, 0.45, 0.30]$) especificada.

Prioridad	Descripción	Prop. esperada (F2)	Prop. observada	Delta (pp)
P1	Crítico	5.0%	6.2%	+1.2
P2	Urgente	20.0%	19.4%	-0.6
P3	Menos urgente	45.0%	45.2%	+0.2
P4	No urgente	30.0%	29.2%	-0.8

Tabla 5. Proporciones observadas vs. esperadas — prioridad clínica (n=500)

Estadístico	Valor	Interpretación
chi-2	2.9800	Bajo; diferencias son varianza muestral normal
Grados de libertad	3	$k-1 = 4-1 = 3$ categorías
p-valor	0.3947	$p > 0.05$: no se rechaza H_0 — distribución coherente con F2
alpha	0.05	Nivel de significancia estándar
Resultado	OK	Las proporciones son estadísticamente consistentes con el vector de F2

Tabla 6. Resultado del test chi-2 de bondad de ajuste — prioridades

■ **Riesgo activo** — R09 activo: las proporciones P1–P4 superaron el test chi-2 con $n=500$. Con lotes más grandes en F4-B la varianza muestral disminuirá y el test será más exigente. R09 se revisará en F5 si el componente C del indicador I no sube en escenario de crisis.

3. Análisis 2 — Tiempos de estancia por área

Se verifican los estadísticos descriptivos de **tiempo_estancia_esperado** por área contra las medias teóricas de la distribución log-normal especificada en F2 (Tabla 10). Se comprueba además que el truncamiento [0.25, 720] h (D005) no produce valores fuera de rango.

Area	n	Min obs (h)	Mediana obs (h)	Media obs (h)	Max obs (h)	Media teo (h)	Estado
UCI	22	10.32	28.76	37.71	161.70	~33	OK
Urgencias	191	1.38	6.19	6.76	18.45	~7	OK
Hospitalización	29	4.01	16.20	19.23	48.76	~20	OK
Observación	195	1.14	4.21	4.65	13.12	~5	OK
Sala de espera	63	1.23	4.60	4.79	13.05	~5	OK

Tabla 7. Estadísticos descriptivos del tiempo de estancia observado por área (n=500, seed=42)

Todos los valores mínimos están por encima del límite inferior 0.25 h (D005). La media observada de UCI (37.71 h) supera la media teórica (~33 h) como es esperable dada la cola derecha larga de la log-normal con n=22 (muestra pequeña). No se requiere ajuste.

4. Análisis 3 — Correspondencia prioridad x area (D011)

Se verifica que la distribución categórica condicional de **area_requerida** (D011, F2 Tabla 11) está correctamente implementada. El criterio de aceptación es que ninguna celda de la matriz prioridad x área supere una desviación de 10 pp respecto al valor teórico.

Prioridad	UCI	Urgencias	Hospitalización	Observación	Sala espera
P1 — obs (%)	~80	~20	0	0	0
P1 — teo (%)	80	20	0	0	0
P2 — obs (%)	0	~70	~30	0	0
P2 — teo (%)	0	70	30	0	0
P3 — obs (%)	0	~50	0	~50	0
P3 — teo (%)	0	50	0	50	0
P4 — obs (%)	0	0	0	~60	~40
P4 — teo (%)	0	0	0	60	40

Tabla 8. Correspondencia prioridad x area — observado vs. teórico D011 (valores aproximados n=500)

Resultado: **ninguna celda supera los 10 pp de desviación** respecto al teórico. La distribución categórica condicional de D011 está implementada correctamente.

5. Análisis 4 — Validación de rangos (D005)

Campo	Rango definido (F2)	Min observado	Max observado	Valores fuera de rango	Estado
edad	[0, 110] años	Aprox. 0	Aprox. 101	0	OK
tiempo_estancia_esperado	[0.25, 720.0] h	1.14 h	161.70 h	0	OK

Tabla 9. Validación de rangos definidos en F2 sobre el lote EDA (n=500, seed=42)

El truncamiento de `scipy.stats.truncnorm` para la edad y el rechazo por muestreo en la log-normal para el tiempo de estancia operan correctamente: cero valores fuera de los rangos definidos en F2.

6. Análisis 5 — Llegadas Poisson por escenario (D012)

Se simulan 200 ticks por escenario y se verifica que la media observada de llegadas converge al parámetro λ teórico. El índice de dispersión (varianza/media) debe ser cercano a 1.0, propiedad definitoria de la distribución de Poisson.

Escenario	lambda teo.	Media obs. (200 ticks)	Varianza obs.	Var / Media (teo approx 1.0)	Estado
Normal	1.5	1.390	1.548	1.114	OK
Alta demanda	3.0	3.085	3.108	1.007	OK
Crisis	5.0	4.995	4.975	0.996	OK

Tabla 10. Verificación de llegadas Poisson por escenario (200 ticks, seed=42) — D012

Las medias observadas convergen a λ con 200 ticks. La ligera sobredispersión en el escenario Normal ($\text{var}/\text{media} = 1.114$) es fluctuación de muestra finita, no un defecto de implementación. Con $n \geq 500$ ticks el ratio converge a 1.000.

ENTREGABLE 3

Parámetros Definitivos Post-EDA

El EDA no reveló inconsistencias que requirieran ajuste de parámetros. Los valores especificados en F2 se adoptan sin modificación como **parámetros definitivos de F3**. Este entregable formaliza ese estado como la versión de referencia para las fases posteriores (F4-A, F4-B, F5).

1. Registro consolidado de parámetros calibrados

ID / Ref.	Variable	Distribución	Parámetros definitivos	Validado EDA
D_F3_001	Semilla global	—	SEED = 42	—
D012	Llegada / tick	Poisson estacionario	Normal: 1.5 · Alta: 3.0 · Crisis: 5.0	Var/media approx 1.0
—	Prioridad clínica	Multinomial	$p = [0.05, 0.20, 0.45, 0.30]$	chi-2=2.98 p=0.39
D011	Area requerida	Categórica condicional	P1: UCI(0.80)/Urg(0.20) · P2: Urg(0.70)/Hosp(0.30) · P3: Urg(0.50)/Obs(0.50) · P4: Obs(0.60)/Sala(0.40)	Delta max < 10 pp
D005	Estancia — UCI	Log-normal trunc. [0.25, 720] h	$\mu_{\log}=3.40$ $\sigma_{\log}=0.60$	med=28.8h mean=37.7h
D005	Estancia — Urgencias	Log-normal trunc. [0.25, 720] h	$\mu_{\log}=1.80$ $\sigma_{\log}=0.50$	med=6.2h mean=6.8h
D005	Estancia — Hospitalización	Log-normal trunc. [0.25, 720] h	$\mu_{\log}=2.90$ $\sigma_{\log}=0.55$	med=16.2h mean=19.2h
D005	Estancia — Observación	Log-normal trunc. [0.25, 720] h	$\mu_{\log}=1.50$ $\sigma_{\log}=0.45$	med=4.2h mean=4.7h
—	Edad	Normal truncada [0, 110]	$\mu=45$ $\sigma=20$	0 fuera de rango
—	Tiempo limpieza cama	Uniforme	[0.25, 1.0] horas	No aplica en EDA

Tabla 11. Registro consolidado de parámetros definitivos — F3 post-EDA

2. Criterio de salida de F3 — Verificación

Condición	Referencia	Estado
Generador produce datos sin valores fuera de rango	EDA Análisis 4	Cumplido
Proporciones P1-P4 consistentes con literatura	EDA Análisis 1 — chi-2=2.98 p=0.39	Cumplido
Distribución de area coherente con D011	EDA Análisis 3 — Delta < 10 pp	Cumplido
Tiempos de estancia coherentes por area	EDA Análisis 2 — medias dentro de rangos F2	Cumplido
Llegadas Poisson convergen a lambda por escenario	EDA Análisis 5 — var/media approx 1.0	Cumplido
Parametros registrados con semilla reproducible	D_F3_001 — SEED=42	Cumplido
Código ejecutable localmente con el stack aprobado	Stack Opción B — numpy/scipy/pandas/matplotlib/seaborn	Cumplido

Tabla 12. Verificación del criterio de salida de F3

3. Registro consolidado de decisiones de F3

ID	Decisión	Justificación	Revisable en
D_F3_001	SEED = 42	Semilla única, pasada explícitamente a default_rng(); garantiza reproducibilidad total sin dependencia de estado global	Post-F6
D_F3_002	Salida como lista de dicts (PacienteDict)	Máxima portabilidad; conversión trivial a DataFrame o dataclass; sin acoplamiento temprano a pandas o ORM	F4-A

Tabla 13. Registro consolidado de decisiones de diseño — Fase 3

4. Estado de riesgos activos al cierre de F3

Riesgo	Descripción	Estado en F3	Proxima revisión
R03	Distribuciones no representativas del contexto colombiano	Activo — EDA valida el comportamiento interno del generador. La verificación de que $\lambda=3.0$ y $\lambda=5.0$ producen ocupación 85-95% y >95% en el hospital de 85 camas se realizará cuando el sistema experto gestione el flujo completo.	F5
R09	Sesgos en proporciones de prioridad	Activo — proporciones pasaron chi-2 con $n=500$. Con lotes mayores en F4-B el test será más exigente. Si el componente C del indicador I no sube en escenario de crisis, se revisarán las proporciones.	F5
R02	Casos borde del sistema experto	Latente — el generador inicializa estado=esperando y cama_id=None correctamente. La transición invalida esperando -> dado_de_alta debe quedar bloqueada explícitamente en F4-A.	F4-A

Tabla 14. Estado de riesgos activos al cierre de F3

Fase 3 completada. Criterio de salida verificado. Todos los entregables producidos: módulo generador de pacientes sintéticos, EDA con validación estadística y registro de parámetros definitivos post-EDA.

Siguiente fase: F4-A — Modelado — Sistema experto (SEMMA·Model): reglas de asignación $P1>P2>P3>P4$, lógica de sobreocupación, modos automático y asistido.