

SIMULADOR INTELIGENTE DE OCUPACION HOSPITALARIA

Fase 4-B — Modelado — Modelo Predictivo (SEMMA-Model)

Proyecto	Prototipo academico funcional · Curso IA en Salud
Fase	F4-B — SEMMA-Model · Modelo Predictivo
Autor	Juan Camilo Garcia Braham
Programa	Maestria en IA y Ciencia de Datos
Institucion	Universidad Tecnologica de Pereira (UTP)
Marco	CRISP-DM/S · SEMMA · DAMA · MLOps
Anno	2026

Resumen ejecutivo

Este documento constituye el entregable completo de la Fase 4-B (Modelado — Modelo Predictivo) del Simulador Inteligente de Ocupacion Hospitalaria, desarrollado bajo el framework CRISP-DM/S con subciclo SEMMA-Model. Contiene: (1) la definicion formal del problema de prediccion (variable objetivo O_{t+4} , horizonte T+4, 15 features); (2) la seleccion y justificacion de dos algoritmos candidatos (Regresion Lineal como baseline y Random Forest como alternativo); (3) el entrenamiento con split 80/20 estratificado y reporte de RMSE/MAE para ambos modelos; y (4) el modelo final documentado con parametros, metricas y artefactos listos para F6. El criterio de salida de F4-B se declara cumplido: modelo final Regresion Lineal con RMSE=2.6429 pp y MAE=2.0639 pp, semilla SEED=42 documentada, artefacto modelo_final_f4b.pkl serializado y listo para integracion en F6.

TABLA DE CONTENIDO

Seccion	Contenido	Pag.
Entregable 1	Definicion del problema de prediccion	3
Entregable 2	Seleccion y justificacion de algoritmos	4
Entregable 3	Entrenamiento y evaluacion (RMSE / MAE)	5
Entregable 4	Modelo final documentado y criterio de salida	8

ENTREGABLE 1

Definicion del Problema de Prediccion

1.1 Variable objetivo

La variable objetivo es O_{t+4} — el porcentaje de ocupacion global del hospital en el tick T+4 (horizonte de 1 hora). Se calcula de forma identica al componente O del indicador I definido en F1: $\text{camas_ocupadas} / \text{camas_validas} * 100$, donde camas_validas excluye las camas en estado en_limpieza . La eleccion de O como variable objetivo (y no I directamente) se justifica en D_F4B_001: predecir I forzaria al modelo a aprender cuatro relaciones causales simultaneas sin separacion de causas, reduciendo interpretabilidad sin ganancia predictiva.

D_F4B_001 — Variable objetivo: O_{t+4}

$O_{t+4} = (\text{camas_ocupadas} / \text{camas_validas}) * 100$ en tick T+4. Coherencia con el sistema experto; interpretabilidad clinica maxima; evita multicolinealidad de predecir I directamente.

1.2 Horizonte temporal: T+4 ticks (1 hora)

El horizonte de prediccion es T+4 ticks ($4 \times 15 \text{ min} = 1 \text{ hora}$). T+1 tiene correlacion trivialmente alta con T (inercia del sistema), aportando poco valor operativo. T+4 es el minimo clinicamente accionable: permite al personal tomar decisiones de redistribucion antes de que la sobreocupacion ocurra. Horizontes mayores (T+8 en adelante) introducen ruido excesivo dado que λ es fija por escenario (D012).

D_F4B_002 — Horizonte: T+4 ticks (1 hora)

Minimo clinicamente accionable. Bajo ruido dado λ fija (D012). Horizontes $> T+8$ dominados por varianza Poisson acumulada.

1.3 Features de entrada (15 variables)

Las 15 features se extraen directamente de ResultadoTick al final de cada tick, sin modificar sistema_experto.py (D_F4B_003). Incluyen los cuatro componentes del indicador I, contadores de eventos del tick, cuatro lags del componente O y dos variables dummy del escenario.

Feature	Fuente en ResultadoTick	Tipo
O_t, E_t, P_t, C_t	componente_O/E/P/C	Continua [0,100]
I_t	indicador_I	Continua [0,100]
$llegadas_t$	$\text{len}(\text{nuevos_pacientes})$	Entera ≥ 0
$altas_t$	conteo acciones tipo alta	Entera ≥ 0
$traslados_t$	conteo acciones tipo traslado/desborde	Entera ≥ 0
$cola_espera_t$	$\text{len}(\text{pacientes_esperando}())$	Entera ≥ 0
$O_lag1 \dots O_lag4$	O_t de ticks t-1 a t-4 (D_F4B_005)	Continua [0,100]
$\text{escenario_alta_demanda}$	one-hot del escenario	Binaria {0,1}
escenario_crisis	one-hot del escenario	Binaria {0,1}

D_F4B_003/004/005 — Features, dataset y lags

Features desde ResultadoTick sin modificar SE (separacion de responsabilidades). Dataset: 3 escenarios x 4 semillas x 196 ventanas = 2.304 filas. 4 lags de O capturan la inercia del proceso de ocupacion hospitalaria.

ENTREGABLE 2

Selección y Justificación de Algoritmos

2.1 Contexto y restricciones del espacio de búsqueda

Con ~2.400 filas y 15 features el proyecto se encuentra en el régimen de datos pequeños. Esto excluye redes neuronales profundas y boosting pesado (XGBoost/LightGBM), cuyo valor diferencial requiere volúmenes mayores y penaliza interpretabilidad. El criterio dominante es: modelo que generalice bien con datos pequeños y cuyos parámetros sean explicables en el informe académico.

Restricción	Valor	Fuente
Tamaño del dataset	~2.304 filas	D_F4B_004
Features	15 (continuas + 2 one-hot)	D_F4B_001..005
Target	$O_{\{t+4\}}$ continuo [0,100]	D_F4B_001
Interpretabilidad	Alta — académico/clínico	F1 CE
Entorno	Local, Python 3.12, sin GPU	Estado actual

2.2 Algoritmo 1 — Baseline: Regresión Lineal Múltiple

La ocupación hospitalaria es un proceso con memoria de corto plazo (lags O) y perturbaciones aditivas (llegadas Poisson, altas). Un modelo lineal captura esta estructura cuando las relaciones son aproximadamente lineales, como ocurre en el rango normal a alta demanda. Sus coeficientes son directamente interpretables y sirve como cota inferior: cualquier alternativa que no supere su RMSE no justifica mayor complejidad. Se implementa con StandardScaler previo para comparabilidad de coeficientes entre features de escalas distintas.

D_F4B_006 — Baseline: LinearRegression (sklearn)

Pipeline: StandardScaler + LinearRegression. Sin regularización. Interpretabilidad máxima. Sin hiperparámetros a ajustar. Cota inferior de desempeño frente al modelo alternativo.

2.3 Algoritmo 2 — Alternativo: Random Forest Regressor

Random Forest es el candidato natural por tres razones: (1) captura no linealidades sin configuración compleja — el efecto techo al 100% de ocupación y los umbrales del indicador I son discontinuidades que el modelo lineal no modela bien; (2) es robusto con datos pequeños usando $n_{\text{estimators}}=100$; (3) `feature_importances_` permite mostrar que variables del sistema experto son más predictivas, conectando narrativamente F4-A con F4-B.

Hiperparámetro	Valor	Justificación
<code>n_estimators</code>	100	Estabiliza varianza con datos pequeños
<code>max_depth</code>	None	Deja que la validación detecte overfitting
<code>random_state</code>	42	Semilla global D_F3_001 — reproducibilidad
<code>n_jobs</code>	-1	Todos los cores; sin impacto en resultados

D_F4B_007/008/009 — RF, stack y hiperparámetros

RandomForestRegressor(`n_estimators=100`, `random_state=42`). Stack ampliado con scikit-learn 1.8 y joblib 1.5 (D_F4B_008). Hiperparámetros fijos sin búsqueda exhaustiva — PMV académico (D_F4B_009).

2.4 Algoritmos descartados

Candidato	Razon del descarte
Ridge / Lasso	Util si hay multicolinealidad severa. Con 15 features y ~2.400 filas no es prioritario.
Gradient Boosting / XGBoost	Overkill para ~2.400 filas. Requiere tuning de lr, n_estimators, profundidad.
SVR	Sensible a escala; requiere busqueda de kernel + C + epsilon. Peor ratio esfuerzo/resultado.
Redes neuronales	Dataset demasiado pequeno. Sin interpretabilidad adicional. Fuera de alcance del PMV.

ENTREGABLE 3

Entrenamiento y Evaluacion

3.1 Generacion del dataset de entrenamiento

El dataset se genero ejecutando 12 simulaciones completas (3 escenarios x 4 semillas), cada una de 200 ticks (50 horas simuladas). De cada simulacion se extrajeron todas las ventanas validas (tick T con target en T+4), descartando los primeros 4 ticks sin lags completos. El resultado fue 2.304 filas con distribucion balanceada: 768 por escenario.

Parametro	Valor
Ticks por simulacion	200 (50 horas simuladas)
Escenarios	normal / alta_demanda / crisis
Semillas	42, 123, 456, 789 (D_F3_001 base)
Filas totales	2.304
Filas por escenario	768
Features	15
Target — media	59.97% (std=16.98, min=11.58, max=96.63)
Formato guardado	dataset_f4b.parquet (pyarrow)

3.2 Split de entrenamiento / validacion

Division 80/20 con train_test_split estratificado por escenario (random_state=42). La estratificacion garantiza que los tres escenarios esten representados proporcionalmente en ambos conjuntos: 1.843 filas de entrenamiento y 461 de validacion.

3.3 Metricas en el set de validacion (20%)

Modelo	RMSE (pp)	MAE (pp)	N test	Resultado
Regresion Lineal	2.6429	2.0639	461	GANADOR
Random Forest	2.7797	2.1213	461	—

Modelo seleccionado: REGRESION LINEAL — RMSE=2.6429 pp | MAE=2.0639 pp
Diferencia de RMSE entre modelos: 0.1368 pp < umbral de 1.0 pp. Criterio de parsimonia (navaja de Occam): cuando la diferencia es menor a 1 pp se selecciona el modelo de menor complejidad. El modelo lineal es el ganador.

3.4 Figuras de evaluacion




Figura 1. Scatter real vs predicho y graficos de residuos para ambos modelos. Ambos se alinean a la linea ideal sin sesgo sistematico. Los residuos del modelo lineal son simetricos alrededor de 0, confirmando linealidad en el rango cubierto por el dataset.




Figura 2. Importancia de features del Random Forest. O_t concentra el 91.3% de la importancia. Los lags O_{lag1} y O_{lag2} aportan 3.3% y 1.9% respectivamente. Las demas features tienen contribucion marginal.

3.5 Interpretacion y diagnostico del error

Un RMSE de 2.64 pp es clinicamente aceptable: la diferencia entre predecir 87% y 90% de ocupacion es operativamente equivalente (activan las mismas reglas del sistema experto). El error residual no proviene del modelo sino del proceso: la variabilidad inherente del proceso Poisson de llegadas constituye ruido irreducible. No se requiere retorno a F3.

R03 — Distribuciones no representativas — Estado actualizado

La distribucion balanceada del target por escenario (normal ~42%, alta_demanda ~62%, crisis ~75%) confirma cobertura de los tres rangos. R03 se declara PARCIALMENTE MITIGADO en F4-B. Verificacion final pendiente en F5.

ENTREGABLE 4

Modelo Final Documentado

4.1 Parametros del modelo final

El modelo final es un Pipeline de scikit-learn: StandardScaler seguido de LinearRegression. Los coeficientes estan en el espacio escalado. La alta colinealidad entre I_t y sus componentes (O, E, P, C) produce coeficientes de signo contrario compensatorio — comportamiento esperado en un modelo predictivo (no inferencial).

Feature	Coeficiente (espacio escalado)
O_t	-173.033929
E_t	-234.962386
P_t	-100.028781
C_t	-47.068498
I_t	+510.911969
llegadas_t	+0.321685
altas_t	-0.256451
traslados_t	-0.873512
cola_espera_t	+0.096215
O_lag1	+2.189061
O_lag2	-0.179530
O_lag3	-1.386623
O_lag4	-0.169560
escenario_alta_demanda	+1.554696
escenario_crisis	+2.860684
intercepto	+60.002528

4.2 Ficha tecnica del modelo final

Parametro	Valor
Algoritmo	Regresion Lineal Multiple (sklearn.LinearRegression)
Pipeline completo	StandardScaler + LinearRegression
RMSE (validacion)	2.6429 pp
MAE (validacion)	2.0639 pp
N entrenamiento	1843
N validacion	461
Split	80/20 estratificado por escenario
Semilla (SEED)	42 (D_F3_001 — semilla global del proyecto)
Features	15 (ver Tabla de features — Entregable 1)

Parametro	Valor
Target	target_O_t4 = O_{t+4} (horizonte T+4 = 1 hora)
Archivo serializado	modelo_final_f4b.pkl (joblib 1.5 / scikit-learn 1.8)

4.3 Registro consolidado de decisiones F4-B

ID	Decision	Justificacion	Rev.
D_F4B_001	Variable objetivo: O_{t+4}	Coherencia con SE; interpretabilidad; evita multicolinealidad de predecir F5	F5
D_F4B_002	Horizonte: T+4 (1 hora)	Minimo clinicamente accionable; bajo ruido dado lambda fija	F5
D_F4B_003	Features desde ResultadoTic	Separacion de responsabilidades; SE no se modifica en F4-B	—
D_F4B_004	Dataset multi-escenario3 esc x 4 semillas x 196 ventanas = 2.304 filas; 3 rangos cubiertos		F5
D_F4B_005	4 lags de O como features	Captura inercia; la ocupacion tiene memoria de corto plazo	—
D_F4B_006	Baseline: LinearRegression	Cota inferior; interpretabilidad maxima; sin hiperparametros	—
D_F4B_007	Alternativo: RandomForestRegression	Captura no linealidades; importancia de features interpretable	—
D_F4B_008	Stack: scikit-learn 1.8 + joblib 1.5	Necesario para modelos y serializacion .pkl	—
D_F4B_009	HP de RF fijos sin busqueda	PMV academico; ajuste manual justificado por tamano del dataset	F6
D_F4B_010	Parsimonia si diff RMSE < 1 pp	Diff = 0.1368 pp < 1.0 pp -> Regresion Lineal ganadora	—

4.4 Estado de riesgos al cierre de F4-B

ID	Descripcion	Estado en F4-B	Prox. revision
R02	Casos borde del sistema experto	MITIGADO en F4-A. Sin nuevas activaciones en F4-B.	F5
R03	Distribuciones no representativas	PARCIALMENTE MITIGADO. Verificacion final en F5.	F5
R09	Sesgos en reglas del SE	MITIGADO en F4-A. F4-B no introduce reglas nuevas.	F5

4.5 Artefactos producidos

Artefacto	Descripcion
generar_dataset_f4b.py	Generador del dataset (simulaciones multi-escenario multi-semilla)
entrenar_modelo_f4b.py	Pipeline completo: entrenamiento, evaluacion, figuras, serializacion
dataset_f4b.parquet	Dataset 2.304 filas x 19 columnas (15 features + target + metadatos)
modelo_final_f4b.pkl	Modelo final — Pipeline StandardScaler + LinearRegression (listo para F6)
modelo_lineal_f4b.pkl / modelo_rf_f4b.pkl	Pipelines individuales para referencia y comparacion
metricas_f4b.json	Metricas, coeficientes e importancias en formato JSON estructurado
fig_prediccion_f4b.png	Scatter real vs predicho y graficos de residuos (ambos modelos)
fig_importancia_f4b.png	Importancia de features del Random Forest

4.6 Criterio de salida de F4-B — Verificacion

Condicion	Referencia	Estado
El modelo alcanza errores dentro del rango aceptable para el dominio	RMSE=2.64 pp < umbral clinico ~5 pp	CUMPLIDO
La eleccion del algoritmo esta justificada con al menos dos candidatas	D_F4B_006, D_F4B_007, D_F4B_010	CUMPLIDO
Division 80/20 con reporte de RMSE y MAE	Secciones 3.2 y 3.3	CUMPLIDO
Artefactos .pkl listos para F6	modelo_final_f4b.pkl (joblib)	CUMPLIDO
Semilla aleatoria documentada	SEED=42 (D_F3_001)	CUMPLIDO
Decisiones D_F4B_001 a D_F4B_010 registradas	Seccion 4.3 de este documento	CUMPLIDO

Fase 4-B completada. Criterio de salida verificado.
Modelo final: Regresion Lineal Multiple | RMSE=2.6429 pp | MAE=2.0639 pp | SEED=42 | 2.304 filas | 15 features | modelo_final_f4b.pkl listo para F6. Siguiente fase: F5 — Evaluacion con escenarios completos (SEMMA-Assess). R03 pendiente de verificacion final en F5.